

Patrones de migración interna en México y su relación con la violencia y la vulnerabilidad social

Presentación Final

Abril 2026

Elvia Castro A00471560

Norma Sánchez A01470352

Alberto Robles A00937035



**Territorial
Intelligence Lab**

Data-Driven Insights for policy
and development

Formulación del Problema - Solución

1. Problema Emigración interestatal impulsada por la violencia y condiciones de vulnerabilidad social.	2. Objetivo Analizar y predecir los flujos de migración interestatal en México, para identificar dinámicas regionales y su relación con la violencia y condiciones de vulnerabilidad social.	3. Acciones propuestas Diseñar una gobernanza proactiva, basada en evidencia, que permita comprender y anticipar cómo la inseguridad y la pobreza impulsan la migración interestatal. • Desarrollar un modelo de regresión que estime el flujo migratorio. • Identificar los factores con mayor peso predictivo en la movilidad (feature importance).
4. Datos Disponibles • Migración Nacional (CONAPO). • Pobreza Multidimensional (CONEVAL). • Índice de Violencia Nacional (SESNSP).	5. Análisis Soluciones focalizadas en: • Alertas Tempranas • Fortalecimiento territorial diferenciado • Optimización Presupuestaria • Mitigación de riesgos migratorios proyectados	6. Consideraciones Éticas Se preserva la privacidad al analizar únicamente tendencias agregadas, no trayectorias individuales. El algoritmo se entrena para identificar relaciones socioeconómicas, no para estigmatizar territorios por su ubicación.

Formulación del Problema – Solución

PREGUNTAS	RESPUESTA
¿Cada cuánto se toma acción/decisión?	Anual
¿Quiénes están incluidos en el análisis?	El análisis se centra en las 32 entidades federativas de México.
¿Cuál es la salida?	La salida del modelo es un valor numérico proyectado y un nivel de riesgo. • Dato Cuantitativo: El número estimado de personas que emigrarán de un estado específico en un periodo determinado. • Dato Cualitativo: Jerarquizar los estados por urgencia, identificando focos rojos de atención inmediata.
¿Qué resultado se está prediciendo?	El flujo migratorio (emigración) por entidad federativa.
¿Para qué propósito?	Como primer acercamiento, se propone un Modelo de Gestión Proactiva Anual con los siguientes objetivos: • Vincular los hallazgos del algoritmo con la planeación presupuestal para convertir datos en inversión social estratégica. • Anticipar necesidades en zonas de alto riesgo migratorio mediante indicadores actualizados, optimizando una respuesta institucional preventiva.

Estructura Técnica

- **Tipo de Problema:**

- Regresión.
- El objetivo es predecir una cantidad numérica continua en el flujo migratorio en las entidades federativas.

- **Definición de Variables:**

- **Variable Objetivo:** EMIGRANTES, la cual representa el número total de personas que salieron de cada entidad federativa.
- **Justificación Conceptual:** La emigración sintetiza el impacto de la precariedad económica y la inseguridad, y permite medir su impacto real en el desplazamiento humano.
- **Predictores:**
 - **Víctimas Totales:** Sumatoria de víctimas de delitos por entidad.
 - **Homicidios:** Indicador de violencia letal.
 - **Extorsiones:** Delito que impacta directamente el patrimonio y la movilidad.
 - **Índice de pobreza:** Porcentaje de la población en situación de pobreza.


- **Modelado:**

- **Modelo Baseline:** Regresión Lineal Múltiple
- **Modelo Intermedio:** Random Forest Regressor (RFR)
- **Modelo Flexible:** Random Forest Regressor (RFR) + *Feature Importance*

Modelos

Modelo 1. Baseline Regresión Lineal Múltiple

Descripción Técnica	- Se utiliza un modelo que ajusta una ecuación lineal a los datos observados. - Se busca minimizar la diferencia entre los valores reales y las estimaciones del modelo.
Supuestos	- Linealidad en la relación. - Independencia entre los errores. - Normalidad en la distribución de los residuos. - Varianza constante.
Ventajas	- Alta eficiencia computacional - Claridad de exposición superior. - Permite cuantificar el impacto unitario de cada factor de riesgo sobre la emigración.
Desventajas	- Limitaciones para capturar comportamientos no lineales o efectos de "umbral". - Altamente sensible a valores atípicos
Riesgo de Sobreajuste	Se considera bajo, dada la estructura de los datos por entidad federativa.
Nivel de Interpretabilidad	Muy Alto. Es la herramienta estándar para establecer causalidad y explicar resultados a audiencias no técnicas




Modelos

Modelo 2. Intermedio

Random Forest Regressor (RFR)


Descripción Técnica	- Algoritmo de ensamble basado en “Bagging”. - Bosque de 100 árboles de decisión independientes. - Cada árbol se entrena con submuestras aleatorias de datos y variables. - La predicción final es el promedio de todos los árboles.
Supuestos	- No requiere una distribución específica de los datos. - No asume una relación lineal entre las variables.
Ventajas	- Alta capacidad para gestionar datos ruidosos y relaciones complejas. - Robusto frente a valores atípicos. - Permite jerarquizar de manera automatizada la importancia de cada variable predictora.
Desventajas	Reduce la transparencia en la trazabilidad de decisiones individuales para cada caso específico.
Riesgo de Sobreajuste	Moderado/Alto debido al tamaño de la muestra (32 entidades).
Nivel de Interpretabilidad	Medio. Permite identificar qué factores tienen mayor peso estratégico en el fenómeno global.



Modelos

Modelo 3. Flexible
Random Forest Regressor (RFR) + Feature Importance

Descripción Técnica	- Algoritmo de ensamble basado en “Bagging”. - Bosque de 100 árboles de decisión independientes. - Cada árbol se entrena con submuestras aleatorias de datos y variables. - La predicción final es el promedio de todos los árboles.
Supuestos	- No requiere una distribución específica de los datos. - No asume una relación lineal entre las variables. - Posible dependencia histórica en la emigración.
Ventajas	- Alta capacidad para gestionar datos ruidosos y relaciones complejas. - Robusto frente a valores atípicos. - Permite jerarquizar de manera automatizada la importancia de cada variable predictora. - Permite considerar el factor temporal.
Desventajas	- Reduce la transparencia en la trazabilidad de decisiones individuales para cada caso específico. - Implica la posibilidad de un mayor peso en un modelo de series de tiempo.
Riesgo de Sobreajuste	Moderado/Alto debido al tamaño de la muestra (32 entidades).
Nivel de Interpretabilidad	Medio. Permite identificar qué factores tienen mayor peso estratégico en el fenómeno global.



Estrategia de División	- Validación Cruzada de K-Pliegues (K-Fold Cross-Validation, K=3): - Datos se dividen en tres subgrupos. El modelo se entrena con dos grupos y se evalúa con el tercero. - Al finalizar, cada entidad del país ha sido utilizada tanto para el aprendizaje como para la validación. - Esta estrategia garantiza que las conclusiones no dependan de una selección aleatoria. - Enfoque de Validación Temporal: - Se usan predictores de periodos previos para estimar la emigración de 2020 y asegurar coherencia causal. - Confirma que el modelo anticipa desplazamientos futuros a partir de condiciones históricas.
Métricas de Evaluación	- Error Absoluto Medio (MAE): Representa el promedio de la diferencia entre la emigración con predicción y la real por estado. - Raíz del Error Cuadrático Medio (RMSE): Promedio de las diferencias al cuadrado, lo que penaliza con mayor rigor los errores de gran magnitud. - Coefficiente de Determinación (R2): Indica la proporción de la variabilidad del flujo migratorio explicada por las variables de seguridad y pobreza. - MRLM = 0.85, RFR V1 = 0.87, RFR V2 = 0.89
Costo Social	- Subestimación de flujo migratorio: - Modelo demasiado optimista = Servicios sin preparación, incrementando la vulnerabilidad de los desplazados. - Equidad Algorítmica: Garantía de visibilidad y justicia territorial - El algoritmo puede sesgarse hacia regiones con más datos o desarrollo, invisibilizando zonas marginadas. - Se realiza un análisis de residuos por región para asegurar errores uniformes y evitar sesgos geográficos.

Consideraciones Éticas

- **Privacidad y Confidencialidad:**

El modelo usa datos estatales agregados sin información de identificación personal, garantizando privacidad y enfocándose en tendencias colectivas.

- **Mitigación del sesgo algorítmico:**

Se reconoce el riesgo de sesgos; por ello se excluyen variables geográficas como predictoras directas. El modelo se entrena en causalidad socioeconómica (pobreza y violencia), evitando estigmatización territorial.

- **Transparencia y Trazabilidad:**

Se documenta todo el proceso garantizando transparencia, auditabilidad y comprensión de datos, transformaciones y criterios de predicción. A diferencia de los modelos de "caja negra", se prioriza la capacidad de explicar “por qué” el modelo arroja un resultado específico.

Limitaciones

- **Limitaciones de los Datos**
 - Subregistro en incidencia delictiva
 - Pérdida de granularidad municipal
 - Falta de datos en tiempo real
- **Restricciones metodológicas**
 - Correlación $\neq$ causalidad.
 - Limitaciones ante dinámicas atípicas.
- **Supuestos Realizados**
 - Continuidad de tendencias históricas.
 - Impacto homogéneo de violencia y pobreza dentro de cada estado.
- **Problemas de Generalización**
 - Modelo específico para México. No transferible sin reentrenamiento completo.
 - Sensible a cambios en política pública.

Implementación e Impacto

Uso Práctico

La salida del modelo debe alimentar un Sistema de Alerta Temprana.

Los resultados estiman la migración e identifican estados donde violencia y pobreza superan niveles sostenibles.

Los resultados del algoritmo tienen aplicaciones directas en decisiones estratégicas:

- Asignación presupuestaria
- Planificación de infraestructura de acogida
- Prevención focalizada

Programa Piloto (12 Meses)

- **Fase Piloto:** Aplicación del modelo en tres entidades federativas con perfiles contrastantes.
- **Calibración en tiempo real:** Comparación de predicciones con flujos migratorios observados.
- **Escalabilidad:** Tras validación, integración de datos municipales para mayor precisión e intervención a microescala.

Indicadores de Impacto:

- **Eficiencia en la respuesta (ER):** Reducción del tiempo de reacción institucional ante desplazamientos previstos.
- **Precisión de la planificación (PP):** Coincidencia entre recursos asignados y demanda real de servicios de la población desplazada.
- **Índice de equidad en la atención:** Cobertura de apoyo en regiones previamente invisibilizadas priorizadas por el modelo.