

CIENCIA DE DATOS AVANZADA

Profesora: Dra. Natalia Cadavid

Alumno	Matrícula
Elvia Castro	A00471560
Norma Sánchez	A01470352
Alberto Robles	A00937035

1. Introducción y justificación del problema

1.1 Definición del problema

La migración interna en México es un fenómeno dinámico que refleja las desigualdades regionales y la búsqueda de mejores oportunidades de vida. Según datos del Consejo Nacional de Población (CONAPO) y los resultados de la Encuesta Nacional de la Dinámica Demográfica (ENADID), la movilidad dentro del país se concentra principalmente en flujos hacia entidades con mayores condiciones de seguridad, desarrollo industrial y oferta de servicios.

Históricamente en México, los movimientos se daban del campo a las grandes ciudades (1960 - 1990); sin embargo, las cifras recientes (2000 a la fecha) muestran una tendencia hacia la migración interestatal, donde estados como Quintana Roo, Baja California Sur y Querétaro destacan por tener saldos migratorios positivos, atrayendo a población joven en edad laboral. Por el contrario, entidades como Ciudad de México, Guerrero, Estado de México, Jalisco, Nayarit y Veracruz suelen registrar las mayores tasas de emigración neta. De acuerdo con la ENADID, la principal motivación detrás de estos traslados sigue siendo la búsqueda de mejores oportunidades familiares y de seguridad (alrededor del 40%), seguida muy de cerca por la búsqueda de empleo o el cambio de trabajo (26%), lo que subraya la importancia de la migración como una estrategia de supervivencia y de mejora socioeconómica.

1.2 Importancia social

La importancia social de la migración interna radica en su capacidad para actuar como un mecanismo de redistribución de oportunidades, donde el movimiento de personas permite el acceso a derechos fundamentales —como salud, seguridad, educación y empleo especializado— que el Estado no garantiza de manera uniforme en todo el territorio. Este fenómeno genera una reconfiguración demográfica profunda: mientras las comunidades de origen enfrentan retos como la pérdida de mano de obra joven y el envejecimiento poblacional, las ciudades receptoras se transforman en nodos de intercambio cultural y diversidad, aunque también bajo la presión de una demanda acelerada de infraestructura y servicios urbanos. En última instancia, la migración interna es el reflejo de la resiliencia social, transformando la estructura de la familia tradicional y obligando a una constante adaptación de la identidad colectiva frente a las brechas de desarrollo regional.

1.3. Objetivos

Objetivo General

Analizar y predecir los flujos de migración interestatal en México, para identificar dinámicas regionales y su relación con la violencia y condiciones de vulnerabilidad social.

Objetivos Específicos

- Desarrollar un modelo de regresión que estime el flujo migratorio.
- Identificar mediante *Feature Importance* los factores que tienen mayor peso predictivo en la movilidad.

Esta propuesta redefine la gestión migratoria en México: de un modelo reactivo a una gobernanza proactiva fundamentada en datos. Al integrar fuentes del SESNSP, CONEVAL y CONAPO, el modelo cuantifica cómo la inseguridad impulsa la migración interna, transformando esta evidencia en inteligencia accionable. Este marco de análisis proporciona información para diseñar soluciones focalizadas en:

- Alertas Tempranas: Identificación de riesgos de expulsión inminente mediante análisis de *clustering* y detección de picos de violencia.
- Fortalecimiento territorial diferenciado: Intervenciones socioeconómicas adaptadas a la problemática predominante de cada región, priorizando la seguridad ante contextos de violencia o el bienestar social ante situaciones de vulnerabilidad.
- Optimización Presupuestaria: Asignación estratégica de recursos basada en la correlación técnica entre seguridad pública y estabilidad demográfica.
- Mitigación de Riesgos Migratorios Proyectados: Diseño de políticas preventivas para estados identificados por el modelo como futuros focos de emigración, adelantándose a posibles crisis de desplazamiento mediante programas de inversión social de largo plazo.

2. Estado actual y brecha

La dinámica de la migración interna en México ha experimentado una transformación sustancial: ha dejado de responder exclusivamente a incentivos económicos para configurarse, en gran medida, como un mecanismo de supervivencia estructural. Actualmente, la violencia ejercida por grupos delictivos en diversas entidades federativas se ha consolidado como un factor de expulsión.

La brecha institucional persiste como el mayor obstáculo para la resolución de esta crisis. Existe una desarticulación profunda y crítica entre los registros oficiales y el diseño de políticas públicas, la cual genera un efecto de invisibilización sistemática del fenómeno. Al reducir el desplazamiento a simples cifras de cambios de residencia, el Estado ignora deliberadamente las causas subyacentes, lo que deriva en una total carencia de mecanismos de protección para quienes huyen del crimen organizado. Esta desconexión institucional no es menor: al no reconocer el desplazamiento como un fenómeno “forzado”,

se anula la capacidad del Estado para intervenir, dejando a las víctimas en una situación de vulnerabilidad extrema.

La evidencia sugiere que, durante las últimas dos décadas, el crimen organizado ha operado como el principal catalizador de los flujos migratorios desde los municipios con mayores índices de marginación. Ante esta realidad, las poblaciones locales se ven obligadas a romper sus vínculos comunitarios y abandonar sus hogares, buscando refugio en centros urbanos con la expectativa —a menudo incierta— de hallar mejores condiciones de seguridad y desarrollo.

3. Datos y Análisis Exploratorio

3.1. Descripción de los Datos

El estudio se fundamenta en la integración de diversas bases de datos oficiales de organismos gubernamentales mexicanos, lo que permite una visión multidimensional del fenómeno migratorio.

- Fuentes: Los datos provienen del Consejo Nacional de Población (CONAPO) para cifras demográficas, el Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP) para indicadores de criminalidad y el Consejo Nacional de Evaluación de la Política de Desarrollo Social (CONEVAL) para los índices de pobreza.
- Periodo temporal: El análisis abarca una serie histórica dividida en dos etapas comparativas: un periodo base (2015-2019) y un periodo reciente / proyectado (2020-2025).
- Unidad de análisis: La unidad de observación es la entidad federativa (estado).
- Número de observaciones: El dataset final consolidado consta de 32 registros, correspondientes a los estados de la República Mexicana.
- Variables disponibles:
 - Demográficas: Volumen de emigrantes por estado (histórico y proyectado a 2025).
 - Seguridad: Tasas de homicidios, feminicidios y extorsiones (acumuladas por periodos).
 - Socioeconómicas: Porcentaje de población en situación de pobreza.

3.2. Limpieza y Preparación

Para asegurar la integridad del modelo predictivo, se aplicaron los siguientes procesos de curación de datos:

- Tratamiento de valores faltantes: Dado que se trabaja con fuentes oficiales consolidadas a nivel estatal, la presencia de valores nulos resultó mínima. En casos específicos de series temporales incompletas, se utilizó la imputación basada en la tendencia histórica de la entidad.
- Manejo de outliers: Se identificaron valores extremos en las variables de seguridad (específicamente en estados con picos atípicos de violencia). Estos no fueron eliminados, al representar la realidad crítica del fenómeno; sin embargo, se

trataron mediante escalamiento robusto para evitar sesgos en los modelos de regresión.

- Transformaciones realizadas: Se llevó a cabo la normalización de variables para asegurar la comparabilidad entre las diferentes escalas (por ejemplo, volumen de habitantes frente a índices de pobreza).
- Ingeniería de variables: Se generaron variables derivadas para capturar la dinámica temporal, tales como la variación porcentual de la violencia entre el periodo 1 (2015-2019) y el periodo 2 (2020-2025), lo que permite al modelo interpretar no solo el estado actual, sino la dirección del deterioro o mejora de la seguridad.

3.3. Análisis Exploratorio de Datos (EDA)

El EDA permitió validar las hipótesis iniciales sobre los motores de la migración en México:

- Estadísticas descriptivas: Se observó una alta heterogeneidad entre estados. Mientras que entidades como la Ciudad de México y Veracruz mantienen volúmenes constantes de emigración, estados como Guanajuato mostraron incrementos disruptivos en indicadores de violencia (con registros que superan los 30,000 incidentes de homicidio/feminicidio en el periodo reciente).
- Distribuciones de variables clave: La variable de emigración presenta una distribución sesgada a la derecha, con una concentración de los mayores flujos en un grupo reducido de estados altamente poblados o con conflictos de seguridad agudos.
- Correlaciones: Se halló una correlación positiva y significativa entre el aumento de la extorsión y la intención de emigrar. En el análisis de importancia de variables, la extorsión superó a la pobreza como factor predictivo de movilidad.
- Visualizaciones interpretadas: Los mapas de calor y gráficos de dispersión revelan que el desplazamiento humano no es aleatorio; se observa una alineación geoespacial entre las zonas de mayor incidencia delictiva y los polos de expulsión de población.
- Identificación de patrones y posibles sesgos: Se identificó un sesgo de subregistro en ciertos delitos de baja denuncia (como la extorsión en zonas rurales), factor que fue considerado al interpretar la relevancia de esta variable en el modelo *Random Forest Regressor*.

Demostración de viabilidad: La viabilidad del problema se demuestra empíricamente al observar que las variables de seguridad (extorsión y homicidios) y pobreza explican una varianza significativa del flujo migratorio. La fuerte correlación entre el deterioro de la seguridad pública y el incremento de la emigración proyectada confirma que el modelo posee capacidad predictiva suficiente para ser utilizado como herramienta de análisis en materia de política pública.

4. Definición del Problema de Aprendizaje Automático

4.1. Tipo de Problema

El proyecto se define principalmente como un problema de regresión, ya que el objetivo es predecir una cantidad numérica continua en el flujo migratorio en los estados. Es un aprendizaje supervisado porque el modelo se entrena utilizando datos históricos etiquetados, donde conocemos de antemano el resultado real para ajustar los parámetros del algoritmo (en este caso, un ensamble de 100 árboles de decisión).

4.2. Variable Objetivo

- **Definición precisa:** Se utiliza la variable *EMIGRANTES_2020* (o su proyección *EMIGRANTES_2025* según el bloque de código ejecutado), que representa el número total de personas que salieron de cada entidad federativa.
- **Método de construcción:** Esta variable es un dato cuantitativo absoluto derivado de los registros de CONAPO y el Censo de Población y Vivienda de INEGI. Se estructura en una serie de tiempo que permite contrastar los flujos de periodos anteriores (2010, 2015) con el observado en 2020.
- **Justificación conceptual:** La emigración se selecciona como variable dependiente porque actúa como el indicador síntoma del entorno social. Es el resultado final de la interacción entre la precariedad económica y la inseguridad, permitiendo medir el impacto real de estas condiciones en el desplazamiento humano.
- **Limitaciones:**
 - Escala absoluta: Al usar números totales de emigrantes, estados con mayor población (como el Estado de México) presentan valores muy altos, lo que puede dificultar la detección de patrones en estados pequeños a menos que se normalice.
 - Rezago censal: La variable refleja eventos capturados en momentos específicos del tiempo, pudiendo omitir desplazamientos forzados inmediatos ocurridos entre censos.

4.3. Variables Predictoras

Lista explícita de variables utilizadas:

1. Víctimas Totales (Seguridad): Sumatoria de víctimas de delitos por entidad.
2. Homicidios y Feminicidios: Indicadores de violencia letal.
3. Extorsiones: Delito que impacta directamente el patrimonio y la movilidad.
4. Índice de Pobreza (CONEVAL): Porcentaje de la población en situación de pobreza.

Justificación teórica

Se basa en la **Teoría de Factores de Expulsión (*Push Factors*)**. La violencia institucional y social (homicidios/extorsión) rompe el tejido social y la seguridad física, mientras que la pobreza limita el acceso a derechos básicos. Ambos operan en conjunto para forzar a los individuos a buscar entornos con mayor estabilidad y oportunidades de supervivencia.

Evidencia empírica del EDA

El Análisis Exploratorio de Datos (EDA) en el algoritmo se muestra que:

- Existen **correlaciones lineales moderadas** entre el aumento de víctimas de extorsión y el incremento de la emigración en estados con economías vulnerables.

- El comportamiento de los datos muestra que los estados con "errores altos" en la predicción (como Jalisco o Estado de México) son aquellos donde el volumen poblacional masivo distorsiona la relación directa, sugiriendo que la violencia no es el *único* motor allí.

Variables descartadas y razones

- **ID de Entidad / Nombre del Estado:** Se descartan como predictores para evitar que el modelo "memorice" estados específicos (overfitting) y para asegurar que aprenda la relación entre las *condiciones* (pobreza/violencia) y la migración.
- **Datos de seguridad previos a 2015:** Se descartaron para mantener una ventana temporal de 5 años previa al objetivo (2020), asegurando que la causalidad sea contemporánea.

Tratamiento de colinealidad

Dado que variables como "Homicidios" y "Víctimas Totales" suelen estar altamente correlacionadas, se aplicaron dos estrategias:

Uso de *Random Forest Regressor*: Este modelo es inherentemente robusto ante la colinealidad. Al seleccionar subconjuntos aleatorios de variables para cada árbol - *feature bagging* -, evita que una variable dominante opaque la contribución de otras.

5. Modelos y Algoritmos (Obligatorio)

La metodología empleada sigue una lógica que transita desde la validación estadística tradicional hasta el uso de arquitecturas de aprendizaje automático (*Machine Learning*) para la captura de fenómenos sociales complejos.

5.1. Modelo 1. Baseline: Regresión Lineal Múltiple (OLS)

Este modelo se establece como el punto de partida para identificar relaciones directas y proporcionales entre las variables de seguridad, pobreza y los flujos migratorios.

- **Descripción técnica:** Se utiliza un modelo que ajusta una ecuación lineal a los datos observados. La relación se define mediante la fórmula:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \epsilon$$

, donde se busca minimizar la diferencia entre los valores reales y las estimaciones del modelo.

- **Supuestos:** Se asume linealidad en la relación, independencia entre los errores, normalidad en la distribución de los residuos y varianza constante (homocedasticidad).
- **Ventajas:** Ofrece una alta eficiencia computacional y una claridad de exposición superior. Permite cuantificar el impacto unitario de cada factor de riesgo sobre la emigración.

- **Desventajas:** Presenta limitaciones para capturar comportamientos no lineales o efectos de "umbral" (donde el fenómeno se dispara tras alcanzar cierto nivel de violencia). Es altamente sensible a valores atípicos.
- **Riesgo de sobreajuste:** Se considera bajo, dada la estructura de los datos por entidad federativa.
- **Nivel de interpretabilidad: Muy Alto.** Es la herramienta estándar para establecer causalidad y explicar resultados a audiencias no técnicas.
- **Justificación social:** Este modelo permite validar las hipótesis fundamentales del proyecto: la existencia de una correlación verificable entre las carencias socioeconómicas y el abandono del territorio en México.

5.2. Modelo 2. Intermedio: Random Forest Regressor (RFR)

Identificado como el núcleo del análisis avanzado, este algoritmo se implementa para procesar la multidimensionalidad y el ruido inherente a los datos sociales.

- **Descripción técnica:** Se emplea un algoritmo de ensamble basado en la técnica de *Bagging*. El sistema construye un "bosque" de 100 árboles de decisión independientes, donde cada uno se entrena con submuestras aleatorias de datos y variables. La predicción final se obtiene mediante el promedio aritmético de todos los árboles.
- **Supuestos:** No requiere una distribución específica de los datos (no paramétrico) ni asume una relación lineal entre las variables.
- **Ventajas:** Posee una alta capacidad para gestionar datos ruidosos y relaciones complejas. Es robusto frente a valores atípicos y permite jerarquizar de manera automatizada la importancia de cada variable predictora (*Feature Importance*).
- **Desventajas:** La naturaleza del algoritmo reduce la transparencia en la trazabilidad de decisiones individuales para cada caso específico en comparación con modelos lineales.
- **Riesgo de sobreajuste:** Se califica como Moderado/Alto debido al tamaño de la muestra (32 entidades). Para mitigar este riesgo, se aplica una Validación Cruzada de K-Pliegues ($K=3$), garantizando que el modelo sea capaz de generalizar sus predicciones a contextos no vistos previamente.
- **Nivel de interpretabilidad: Medio.** Aunque carece de una fórmula matemática simple, permite identificar qué factores (ej. extorsión vs. pobreza) tienen mayor peso estratégico en el fenómeno global.
- **Justificación social:** Dado que la migración forzada responde a dinámicas no lineales, el uso de *Random Forest Regressor* permite detectar puntos de quiebre o umbrales críticos de crisis social que los modelos tradicionales suelen omitir, ofreciendo una visión más cercana a la realidad de la seguridad y el desplazamiento en el país.

5.3 Modelo 3. Flexible: Random Forest Regressor (RFR) + Features Importance

El modelo mejorado se distingue por la integración de la función **Feature Importance** (Importancia de Variables), la cual transforma un algoritmo predictivo convencional en una herramienta de análisis explicativo y estratégico. Mientras que las versiones anteriores se centraban en la precisión del cálculo, esta funcionalidad permite jerarquizar de manera objetiva el peso de cada variable —como la extorsión, los homicidios o la pobreza— en la determinación de los flujos migratorios, eliminando la opacidad del modelo y permitiendo identificar los verdaderos motores del fenómeno social.

6. Estrategia de Validación

La validez de un modelo predictivo no reside únicamente en su precisión numérica, sino en su capacidad para generalizar patrones a partir de datos limitados y en la relevancia ética de sus resultados ante el fenómeno sobre la emigración.

6.1 División de Datos

Dada la naturaleza del conjunto de datos, compuesto por 32 entidades federativas, una división estática convencional (entrenamiento/prueba) resultaría insuficiente y con posibles sesgos geográficos. Por ello, se han implementado las siguientes metodologías:

- Validación Cruzada de K-Plieques (K-Fold Cross-Validation, K=3): En lugar de una única evaluación, los datos se dividen en tres subgrupos. El proceso se repite cíclicamente: el modelo se entrena con dos grupos y se evalúa con el tercero. Al finalizar, cada entidad del país ha sido utilizada tanto para el aprendizaje como para la validación. Esta estrategia garantiza que las conclusiones no dependan de una selección aleatoria, sino de la robustez del algoritmo ante la diversidad de todos los estados.
- Enfoque de Validación Temporal: Para asegurar la coherencia causal, se utilizan variables predictoras de periodos previos (violencia y pobreza 2015-2019) para estimar la emigración del año 2020. Esta estructura confirma que el modelo es capaz de anticipar desplazamientos futuros basándose en condiciones históricas acumuladas.

6.2. Métricas de Evaluación

La selección de métricas trasciende el rendimiento técnico para enfocarse en la utilidad pública y la minimización de riesgos humanos. A continuación, se detallan los cálculos basados en la escala de flujo migratorio del proyecto:

Métricas de Desempeño Calculadas:

1. Error Absoluto Medio (MAE): Representa el promedio de la diferencia entre la emigración con predicción y la real por estado.
2. Raíz del Error Cuadrático Medio (RMSE): Promedio de las diferencias al cuadrado, lo que penaliza con mayor rigor los errores de gran magnitud.
3. Coeficiente de Determinación (R2): Indica la proporción de la variabilidad del flujo migratorio explicada por las variables de seguridad y pobreza.

El análisis de los coeficientes de determinación (R2) obtenidos refleja una capacidad explicativa robusta y creciente a través de las distintas versiones del modelo, permitiendo cuantificar la influencia de los factores sociales en la movilidad humana.

Para el **Modelo 1**, se obtuvo un R2 de **0.85**, lo que indica que el 85% de la varianza en los flujos migratorios estatales se explica por las variables iniciales de seguridad y pobreza. En el **Modelo 2**, esta proporción se elevó al **87%**, mientras que el **Modelo 3** alcanzó un valor de **0.89**, consolidando un ajuste superior en la predicción de los datos. Este incremento progresivo en el coeficiente demuestra que el refinamiento de las variables y la integración de funciones como << *Feature Importance* >> han permitido capturar de manera más precisa la relación entre el deterioro del entorno social y el desplazamiento poblacional,

reduciendo el margen de error y validando la efectividad del modelo para interpretar la dinámica migratoria en el contexto mexicano actual.

Tipo de error más costoso

En este proyecto, entendemos que detrás de cada dato hay una persona. Por ello, la evaluación del modelo no se limita a números, sino que integra dos principios fundamentales para la toma de decisiones responsables:

1. Priorización de la respuesta humanitaria (Costo del Error)

No todos los errores de predicción tienen las mismas consecuencias en la vida real. Hemos definido que el error más crítico es la subestimación (predecir menos flujo migratorio del que realmente ocurre).

- ¿Por qué es el más costoso? Si el modelo es "demasiado optimista" y no detecta una emigración inminente, las instituciones, refugios y servicios de salud no estarán preparados para recibir a las familias. Esto genera un vacío de protección que aumenta la vulnerabilidad de las personas desplazadas.
- Nuestra sugerencia: Preferimos un modelo con un margen de seguridad que nos permita estar prevenidos. Es preferible contar con recursos listos que no se utilicen de inmediato, a enfrentar una crisis humanitaria sin capacidad de respuesta.

2. Equidad Algorítmica: Garantía de visibilidad y justicia territorial

El éxito de esta implementación tecnológica no se determina mediante un promedio nacional —el cual puede ocultar disparidades críticas—, sino a través de su capacidad para ofrecer resultados precisos y justos en cada entidad del país. En el desarrollo de modelos predictivos, existe un riesgo inherente de que el algoritmo favorezca a regiones con mayor densidad de datos o mayor desarrollo económico, lo que tiende a invisibilizar a las zonas históricamente marginadas.

Para mitigar este riesgo, se aplica un análisis de residuos por región. Esta técnica permite verificar que el margen de error sea uniforme en todo el territorio; es decir, asegurar que el modelo posea el mismo nivel de sensibilidad y precisión tanto en los estados del sur como en los del norte. Este rigor técnico garantiza que el modelo no replique sesgos geográficos preexistentes.

7. Consideraciones Éticas

El desarrollo del modelo predictivo no solo se rige por estándares de precisión técnica, sino también por un marco de ética y responsabilidad social. Para garantizar la integridad del análisis, se han implementado las siguientes directrices:

7.1. Privacidad y Confidencialidad

El código utiliza exclusivamente datos agregados a nivel estatal provenientes de fuentes oficiales (INEGI, CONEVAL, SESNSP). No se maneja información de identificación

personal (PII), lo que garantiza que los resultados no vulneren la privacidad de ningún individuo ni permitan el rastreo de casos particulares. El análisis se enfoca en flujos demográficos y tendencias colectivas, no en trayectorias personales.

7.2. Mitigación del sesgo algorítmico

Se reconoce que los modelos de aprendizaje automático pueden replicar prejuicios presentes en los datos históricos. Para evitar esto, se han omitido etiquetas o nombres de regiones como variables predictoras directas. El algoritmo es entrenado para identificar la causalidad socioeconómica (pobreza y violencia) y no para estigmatizar geográficamente a ciertos estados por el simple hecho de su ubicación.

7.3. Discriminación indirecta

Para evitar que el modelo genere recomendaciones que afecten desproporcionadamente a grupos vulnerables, se supervisa que las variables utilizadas sean neutras. Se evita el uso de datos que puedan actuar como sustitutos (*proxies*) de características protegidas, asegurando que el modelo identifique necesidades de protección humanitaria basadas en hechos delictivos y carencias materiales, y no en perfiles identitarios.

7.4. Transparencia y trazabilidad

Se mantiene una documentación clara de cada etapa del proceso, desde la limpieza del archivo << *df_final.csv* >> hasta la ejecución del algoritmo en Python. Esta transparencia permite que el proceso sea auditable, permitiendo a los tomadores de decisiones comprender el origen de los datos, las transformaciones realizadas y los criterios bajo los cuales se generan las predicciones.

7.5. Interpretabilidad

A diferencia de los modelos de "caja negra", se prioriza la capacidad de explicar **"por qué"** el modelo arroja un resultado específico. Mediante herramientas de importancia de variables (*Feature Importance*), se puede comunicar a los stakeholders con claridad qué factor (ej. el índice de extorsión o la pobreza) ha tenido mayor peso en la predicción de un flujo migratorio, facilitando una toma de decisiones informada y justificada.

8. Limitaciones

Todo ejercicio de modelado predictivo, especialmente en el ámbito social, opera bajo ciertas restricciones que deben ser consideradas para la correcta interpretación de los resultados y la toma de decisiones informada.

8.1. Limitaciones de los Datos

- Naturaleza de las Fuentes: El modelo se nutre de datos oficiales (INEGI, CONEVAL, SESNSP). No obstante, existe un fenómeno de subregistro en las cifras de incidencia delictiva (cifra negra), lo que implica que el impacto real de la violencia podría ser superior al capturado estadísticamente.
- Escala Territorial: Al trabajar con datos agregados a nivel estatal (32 entidades), se pierde la granularidad municipal. Esto puede ocultar crisis migratorias localizadas en municipios específicos dentro de estados que, en promedio, parecen estables.
- Periodicidad: La variable objetivo (emigración) depende de ciclos censales. La falta de datos de movilidad en tiempo real limita la capacidad del modelo para reaccionar ante eventos de desplazamiento forzado súbito.

8.2. Restricciones metodológicas

- Correlación no es Causalidad: Aunque el modelo identifica una fuerte relación entre pobreza/violencia y emigración, existen factores intervinientes no cuantificados (redes de apoyo familiar en el extranjero, desastres climáticos o políticas migratorias de terceros países) que influyen en la decisión de migrar.
- Capacidad del Algoritmo: Si bien el uso de *Random Forest* captura relaciones complejas, su naturaleza estadística busca patrones generales. El modelo puede presentar dificultades para predecir comportamientos en estados con dinámicas atípicas que no se asemejan al resto del país.

8.3. Supuestos realizados

- Continuidad de la dinámica social: Se asume que los factores que impulsaron la migración en el periodo 2015-2019 mantienen una lógica similar para las proyecciones de 2020-2025. Un cambio estructural en la naturaleza del crimen organizado o en la economía global podría invalidar ciertos patrones aprendidos.
- Homogeneidad del impacto: El modelo asume que el impacto de la violencia y la pobreza es uniforme entre los diferentes estratos de la población dentro de un mismo estado, simplificando la diversidad de experiencias individuales para fines de proyección masiva.

8.4. Problemas de generalización

- Especificidad del contexto mexicano: El modelo ha sido diseñado y entrenado exclusivamente con la dinámica sociopolítica de México. Sus reglas y aprendizajes no son transferibles a otros contextos nacionales o internacionales sin una reconfiguración total de las variables y datos de entrenamiento.
- Sensibilidad a cambios de política: El modelo no contempla cambios drásticos en la política pública o intervenciones gubernamentales futuras. Una mejora sustancial en la seguridad de una región podría reducir la migración de forma más rápida de lo que el algoritmo, basado en tendencias históricas, podría predecir.

9. Recomendaciones de Implementación

La implementación de este modelo no debe verse únicamente como un despliegue técnico, sino como la integración de una herramienta de inteligencia diagnóstica en el ciclo de las políticas públicas y la ayuda humanitaria.

9.1. Protocolo de uso del modelo

El modelo está diseñado para operar de forma cíclica conforme se actualizan los tableros de seguridad y economía.

- **Periodicidad:** Se recomienda una ejecución semestral para ajustar las proyecciones de movilidad según el comportamiento de la incidencia delictiva y los indicadores de carencia social.
- **Nivel de Operación:** La salida del modelo debe alimentar un **Sistema de Alerta Temprana**. Los resultados no solo indican *cuántas* personas podrían migrar, sino que identifican los estados donde la combinación de violencia y pobreza ha cruzado el umbral de sostenibilidad.

9.2. Aplicación en la toma de decisiones

Los resultados del algoritmo tienen aplicaciones directas en decisiones estratégicas:

- Asignación presupuestaria: Dirigir fondos de emergencia a los estados identificados con alto riesgo de éxodo inminente para fortalecer programas de resiliencia local.
- Planificación de infraestructura de acogida: Informar a los estados receptores sobre el volumen estimado de llegada de personas para prevenir el colapso de albergues, servicios de salud y escuelas.
- Prevención focalizada: Implementar programas de intervención social y pacificación en las zonas donde el modelo detecta que la inseguridad es el motor principal de la expulsión poblacional.

9.3. Propuesta de piloto y evaluación futura

Se propone una fase de validación controlada de **12 meses**:

1. Fase Piloto: Aplicar el modelo en tres entidades federativas con perfiles contrastantes (ej. un estado con alta violencia, uno con pobreza extrema y uno estable).
2. Calibración en tiempo real: Comparar las predicciones del modelo con los flujos migratorios reales observados a través de registros administrativos locales durante el primer año.
3. Escalabilidad: Tras la validación, el modelo podrá integrar datos a nivel municipal para aumentar la precisión geográfica y permitir intervenciones a microescala.

9.4. Indicadores de impacto

Para medir el éxito de la implementación, se sugieren los siguientes indicadores clave:

- Eficiencia en la respuesta (ER): Reducción en el tiempo de respuesta institucional ante desplazamientos masivos detectados previamente por el modelo.
- Precisión de la planificación (PP): Porcentaje de coincidencia entre los recursos asignados preventivamente y la demanda real de servicios por parte de la población desplazada.
- Índice de equidad en la atención: Medición de la cobertura de apoyo en regiones históricamente invisibilizadas que ahora son priorizadas gracias a la detección del modelo.

Referencias

Secretaría General del Consejo Nacional de Población (CONAPO). (2025). *Migrantes interestatales por edad y año quinquenales (1970–2069)*. Datos.gob.mx. <https://www.datos.gob.mx/dataset/proyecciones-de-poblacion/resource/0104d214-c9a9-4141-b313-e2a83720a389>

Consejo Nacional de Población (CONAPO). (s. f.). Migración interna en México. Gobierno de México. <https://www.gob.mx/conapo/acciones-y-programas/migracion-interna-en-mexico>

Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). (s. f.). Datos abiertos de incidencia delictiva. Gobierno de México. <https://www.gob.mx/sesnsp/acciones-y-programas/datos-abiertos-de-incidencia-delictiva>

Consejo Nacional de Población (CONAPO). (s. f.). Migración interna: Diccionarios de datos (1990–2010). CONAPO.

Cruz Piñeiro, R., & Acosta Díaz, F. (Coords.). (2015). Migración interna en México: Tendencias recientes en la movilidad interestatal. El Colegio de la Frontera Norte. ISBN 978-607-479-176-1

Consejo Nacional de Evaluación de la Política de Desarrollo Social (CONEVAL). (2015). *Anexo estadístico de pobreza a nivel municipal 2010 y 2015*. https://www.coneval.org.mx/Medicion/Paginas/AE_pobreza_municipal.aspx

Consejo Nacional de Evaluación de la Política de Desarrollo Social (CONEVAL). (2020). *Programas de cálculo de pobreza a nivel municipal 2010–2020*. https://www.coneval.org.mx/Medicion/Paginas/Programas_VCOMPL_mpal_2010-2020.aspx

Consejo Nacional de Evaluación de la Política de Desarrollo Social (CONEVAL). *Página principal*. <https://www.coneval.org.mx/paginas/principal.aspx>

Consejo Nacional de Población (CONAPO). (2019). *La violencia como causa de desplazamiento interno forzado: Aproximaciones a su análisis en México*. https://www.gob.mx/cms/uploads/attachment/file/456109/Desplaz_2019_web_color-comp.pdf

Consejo Nacional de Población (CONAPO). (2020). *Índice de calidad del entorno 2020*. https://www.datos.gob.mx/dataset/indice_calidad_entorno

Consejo Nacional de Población (CONAPO). (2020). *Índice de marginación 2020*. <https://www.gob.mx/conapo/documentos/indice-de-marginacion-2020>

Consejo Nacional de Población (CONAPO). (2026). *Catálogo de publicaciones: Dirección de Poblamiento y Desarrollo Regional Sustentable*. https://www.gob.mx/cms/uploads/attachment/file/1056796/Cat_logo_2026.pdf

Consejo Nacional de Población (CONAPO). *Datos abiertos: Migración interna*. <https://historico.datos.gob.mx/busca/dataset/migracion-interna>

Consejo Nacional de Población (CONAPO). *Página principal*. <https://www.gob.mx/conapo>

Instituto Nacional de Estadística y Geografía (INEGI). (2023). *Encuesta Nacional de la Dinámica Demográfica (ENADID) 2023*. <https://www.inegi.org.mx/programas/enadid/2023/>

Instituto Nacional de Estadística y Geografía (INEGI). (2023). *Nota técnica ENADID 2023*. https://www.inegi.org.mx/contenidos/programas/enadid/2023/doc/nota_tec_enadid23.pdf

Instituto Nacional de Estadística y Geografía (INEGI). (2025). *Encuesta Nacional de Ocupación y Empleo (ENOE)*. <https://www.inegi.org.mx/programas/enoe/>

Instituto Nacional de Estadística y Geografía (INEGI). (2025). *Encuesta Nacional de Victimización y Percepción sobre Seguridad Pública (ENVIPE)*. <https://www.inegi.org.mx/programas/envipe/>

Instituto Nacional de Estadística y Geografía (INEGI). *Glosario: Migración interna*. <https://www.inegi.org.mx/app/glosario/default.html?p=MIGRA2002>

Instituto Nacional de Estadística y Geografía (INEGI). *Página principal*. <https://www.inegi.org.mx/>

Instituto Nacional de Estadística y Geografía (INEGI). *Registro Nacional de Metadatos (ENADID metodología)*. <https://www.inegi.org.mx/rnm/index.php/catalog/981>

Índice MX. (s. f.). *Evolución del Índice de Marginación 2010–2020 (mapa interactivo)*. https://indicemx.github.io/IMx_Mapas/IMM_2010-2020.html#section-2

Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). (2025). *Incidencia delictiva del fuero común (estatal y municipal)*. https://www.datos.gob.mx/dataset/incidencia_delictiva